МИНОБРНАУКИ РОССИИ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«МИРЭА – Российский технологический университет»
РТУ МИРЭА

Институт информационных технологий (ИИТ)
Кафедра прикладной математики (ПМ)

КУРСОВАЯ РАБОТА

по дисциплине «Прикладные задачи математической статистики»

Тема курсовой работы: «Статистический анализ гендерных различий зарплат в разных странах методами математической статистики »

Студент группы ИНБО-21-23 Громов Семён Дмитриевич _____
(подпись)

Руководитель
курсовой работы Ст. Преподаватель Парамонов А.А. _____
(подпись)

Работа представлена к защите «___»_____2025 г.

Допущен к защите «___»_____2025 г.

Москва 2025 г.

МИНОБРНАУКИ РОССИИ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«МИРЭА – Российский технологический университет»
РТУ МИРЭА

Институт информационных технологий (ИИТ)
Кафедра прикладной математики (ПМ)

Утверждаю
Заведующий кафедрой ПМ
_____ Смоленцева Т.Е.
(подпись)
«22» сентября 2025 г.

ЗАДАНИЕ
на выполнение курсовой работы
по дисциплине «Прикладные задачи математической статистики»

Студент Громов Семён Дмитриевич Группа ИНБО-21-23

Тема «Статистический анализ гендерных различий зарплат в разных странах методами математической статистики »

Исходные данные: область анализа, назначенная студенту согласно теме работы и реальные данные из открытых источников

Перечень вопросов, подлежащих разработке, и обязательного графического материала:
Обоснование актуальности темы, формулировка цели, задач, объекта и предмета анализа, краткая характеристика данных; Выполнение предварительного анализа: построение вариационных рядов, гистограмм, эмпирических функций распределения, расчёт выборочных характеристик и точечных оценок с анализом их свойств; Расчёт доверительных интервалов, подбор подходящих статистических критериев и обоснование их выбора, проведение проверки статистических гипотез с использованием параметрических и непараметрических методов; Проведение оценки распределений и плотностей, сравнение результатов с теоретическими моделями, анализ совпадения или расхождения результатов; Определение закона распределения данных с помощью критерия согласия Пирсона и метода анаморфоз, построение графиков и сравнение результатов обоих методов.

Срок представления к защите курсовой работы: **до «19» декабря 2025 г.**

Задание на курсовую работу выдал _____ Парамонов А.А.
Подпись руководителя *(ФИО руководителя)*
«19» сентября 2025 г.

Задание на курсовую работу получил _____ Громов С.Д.
Подпись обучающегося *(ФИО обучающегося)*
«19» сентября 2025 г.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ 4
1 СБОР И ПРЕДВАРИТЕЛЬНЫЙ АНАЛИЗ ДАННЫХ 6
1.1 Анализ целевой переменной 6
1.2 Вычисление точечных оценок 16
2 ОЦЕНКА ПАРАМЕТРОВ РАСПРЕДЕЛЕНИЯ 22
2.1 Расчёт точечных оценок и доверительных интервалов 22
2.2 Расчёт оценок и критериев 25
2.3 Оценка распределений и плотностей 28
2.4 Формирование гипотез 30
2.4.1 Гипотеза о равенстве средних 30
2.4.2 Гипотеза о лог-нормальности данных 30
2.4.3 Гипотеза о равенстве дисперсий 31
3 Идентификация распределения 33
3.1 Критерий согласия Пирсона 33
3.2 Метод анаморфоз 35
3.3 Вывод на основе полученных результатов 38
ЗАКЛЮЧЕНИЕ 39
СПИСОК ИСТОЧНИКОВ 40

ВВЕДЕНИЕ

Гендерное неравенство в оплате труда является актуальной проблемой глобального уровня. Международные исследования демонстрируют, что женщины в среднем зарабатывают на 10–30 % меньше мужчин за равный труд. По некоторым оценкам, средний доход женщин составляет примерно 80 % от дохода мужчин. При этом международная организация труда подчёркивает, что в большинстве стран во всех отраслях мужчины по-прежнему получают более высокую заработную плату, чем женщины. Значимые разрывы наблюдаются даже в высококвалифицированных сферах: например, одно исследование международной организации труда показало, что в более чем 80 % стран разница в оплате труда между мужчинами и женщинами среди специалистов в области науки, инженерии и здравоохранения составляет не менее 5 %. Это свидетельствует о том, что гендерный разрыв в зарплатах – устойчивое явление, требующее глубокого анализа с использованием надёжных статистических методов.

Предметная область анализа гендерных различий в оплате труда пересекает экономику труда, социологию, демографию и политическую экономию. Анализ заработков мужчин и женщин тесно связан с исследованием рынка труда, социальной мобильности, структуры занятости и демографических трендов. Международные и национальные стратегии равенства выделяют необходимость устранения дискриминации, включая равную оплату равного труда. В данной предметной области статистические методы позволяют учитывать сложность и многогранность данных – от уровня образования и отраслевой принадлежности до социальных и культурных факторов – и выявлять устойчивые закономерности в распределении доходов.

Методы математической статистики играют ключевую роль в исследовании гендерного разрыва в оплате труда. С их помощью можно проводить описательный анализ выборок (расчёт вариационных рядов, гистограмм, эмпирических функций распределения, коэффициентов корреляции

и др.) и переходить к выводам, проверяя их на основе выборочных данных. Важной частью анализа является формулировка статистических гипотез и их проверка классическими критериями с вычислением p-value и построением доверительных интервалов.

Целью данной курсовой работы является статистический анализ гендерных различий в оплате труда в разных странах мира. Для достижения этой цели ставятся следующие задачи:

- Собрать и описать данные о средних зарплатах мужчин и женщин в разных странах за выбранные периоды, рассчитать основные статистические характеристики, построить вариационные ряды, гистограммы и эмпирические функции распределения.
- Оценить параметры распределений доходов мужчин и женщин с помощью точечных (метод максимального правдоподобия, метод моментов, байесовские оценки) и интервальных оценок, проверить свойства оценок (несмещенность, состоятельность, эффективность) и построить доверительные интервалы для ключевых статистических характеристик гендерного разрыва.
- Рассчитать статистические показатели, сформировать статистические гипотезы, используя методы проверки статистических гипотез, оценить их достоверность на основе метрик параметрических, непараметрических критериев, а также критериев на распределения, которые возможно оценить на основе оценочных метрик.
- Идентифицировать распределения исследуемых данных двумя способами: с помощью критерия согласия Пирсона, методом анаморфоз. Построить необходимые графики. Найти параметры распределения.

1 СБОР И ПРЕДВАРИТЕЛЬНЫЙ АНАЛИЗ ДАННЫХ

1.1 Анализ целевой переменной

Рассматриваемые данные содержат статистические данные о различиях в уровне заработных плат мужчин и женщин в различных странах мира. Такие данные позволяют количественно оценить гендерный разрыв в доходах и понять, как он проявляется в разных регионах. Анализ информации по странам и годам помогает выделить тенденции в оплате труда и сформулировать выводы для социальной и экономической политики.

Источником данных является [1]. В исследуемых данных представлены как категориальные признаки в виде названий государств или пола рассматриваемой группы, так и числовые (средняя зарплата по группам). Типы данных в датасете представлены в Таблице 1.

Таблица 1 — Основные характеристики столбцов

Столбец	Тип данных	Описание столбца
ref_area.label	String	Место работы группы
sex.label	String	Пол рассматриваемой группы
year	Integer	Год, в котором были собраны данные
obs_value	Float	Сгруппированное среднее значение среднемесячной зарплаты рассматриваемой группы в долларах

Для продуктивной работы с данными необходимо очистить данные от экстремальных значений, а также вычислить классические параметры предварительного анализа отдельно для групп мужчин и групп женщин. Программный расчет параметров представлен на Листинге 1.

Листинг 1 — Расчёт метрик для целевой переменной

```
df = pd.read_csv('data.csv', sep=';')
df.rename(columns={
    'ref_area.label': 'Country', 'sex.label': 'Sex', 'obs_value':
'Value', 'time': 'Year'},
    inplace=True)
```

Продолжение Листинга 1

```
df['Value'] = pd.to_numeric(df['Value'], errors='coerce')
df['Year'] = pd.to_numeric(df['Year'], errors='coerce')

print(f"Количество строк до очистки: {len(df)}")

df.dropna(subset=['Value',     'Sex',     'Country',     'Year'],
inplace=True)

print(f"Количество строк после очистки: {len(df)}")

q1 = df['Value'].quantile(0.025)
q3 = df['Value'].quantile(0.975)
df = df[(df['Value'] >= q1) & (df['Value'] <= q3)]
df = df.groupby(['Country', 'Sex'])['Value'].mean().reset_index()

df_male = df[df['Sex'].str.lower() == 'male']
df_female = df[df['Sex'].str.lower() == 'female']
val = df['Value'].astype('float')
val = val.reset_index(drop=True)
print(min(val))
print(max(val))
```

Количество строк перед очисткой данных = 3978, количество строк после очистки данных = 3976, количество строк после фильтрации крайних значений = 3776. Максимальное значение зарплаты = 6015.6 долларов. Минимальное значение зарплаты = 6.047 долларов.

Построим вариационный ряд по соответствующим данным. Число групп определим по правилу Стёрджесса:

$$g = 1 + 3{,}322 \cdot log_{10} n, \tag{1.1}$$

где n — объем выборки.

Ширина интервала рассчитывается по имеющемуся числу групп:

$$h = \frac{\max(x) - \min(x)}{g}, \tag{1.2}$$

где g — число групп.

Программный расчет построения вариационного ряда представлен на Листинге 2.

Листинг 2 — Построение вариационного ряда

```
h = (val.max() - val.min()) / g
bins = [val.min() + i * h for i in range(g + 1)]
bins[0] -= 1e-3
intervals = pd.cut(val, bins)
abs_freq = intervals.value_counts().sort_index()
rel_freq = round(abs_freq / n, 3)
return_df = pd.DataFrame({
        'intervals':          abs_freq.index,          'abs_freq':
abs_freq,'rel_freq': rel_freq}).reset_index(drop=True)
```

Результаты работы программы показан на Таблице 2.

Таблица 2 — Вариационный ряд зарплат мужчин

Интервалы зарплат	Абсолютная частота	Относительная частота
(148.811, 882.161]	104	0.675
(882.161, 1615.509]	12	0.078
(1615.509, 2348.858]	8	0.052
(2348.858, 3082.206]	10	0.065
(3082.206, 3815.554]	5	0.032
(3815.554, 4548.903]	5	0.032
(4548.903, 5282.252]	6	0.039
(5282.252, 6015.6]	4	0.026

Результаты работы программы (вариационный ряд зарплат групп женщин) показан на Таблице 3.

Таблица 3 — Вариационный ряд зарплат женщин

Интервалы зарплат	Абсолютная частота	Относительная частота
(138.867, 860.491]	104	0.675
(860.491, 1582.114]	18	0.117
(1582.114, 2303.736]	12	0.078
(2303.736, 3025.359]	8	0.052
(3025.359, 3746.982]	3	0.019
(3746.982, 4468.604]	2	0.013
(4468.604, 5190.227]	6	0.039
(5190.227, 5911.85]	1	0.007

Визуализируем имеющиеся и вычисленные данные. Найдём абсолютную и относительную частоту, построим гистограмму для соответствующих данных.

Вычислим эмпирическую функцию распределения и построим её график. Эмпирическая функция распределения рассчитывается по следующей формуле:

$$F_n(x) = \frac{x_i \leq x}{n} = \frac{1}{n}\sum_{i=1}^{n} I(x_i \leq x), \tag{1.3}$$

где $F_n(x)$ — значение эмпирической функции распределения в точке x;

n — общее число наблюдений в выборке;

x_i — i-е наблюдение признака.

Программный расчет вышеприведённых визуализаций представлен на Листинге 3.

Листинг 3 — Визуализация имеющихся данных

```
return_df['low_interval'] = return_df['intervals'].apply(lambda x:
x.left)

     return_df['center_interval']                                =
return_df['intervals'].apply(lambda x: x.mid)
    return_df['up_interval']

 = return_df['intervals'].apply(lambda x: x.right)

 plt.step(return_df['up_interval'],            return_df['empf'],
where='post')

    plt.scatter(return_df['up_interval'],      return_df['empf'],
color='blue')

    plt.xticks(rotation=45)
    plt.locator_params(axis='x', nbins=20)

    plt.title("Эмпирическая функция распределения показателя")
    plt.xlabel("Значение показателя (Value)")
    plt.ylabel("Относительная частота")

    plt.grid(True)
    plt.show()

    left = [interval.left for interval in return_df['intervals']]

    right     =     [interval.right     for     interval     in
return_df['intervals']]
```

Продолжение Листинга 3

```
    widths = [r - l for l, r in zip(left, right)]
    freq = return_df['rel_freq']

    plt.figure(figsize=(8, 6))

plt.bar(left, freq, width=widths, align='edge', edgecolor='black')

    plt.xlabel("Значение показателя (Value)")
    plt.ylabel("Относительная частота")

    plt.title("Гистограмма распределения показателя")

    plt.xticks(rotation=45)
    plt.locator_params(axis='x', nbins=20)

    plt.show()
```

Гистограмма распределения зарплат мужчин представлена на Рисунке 1.

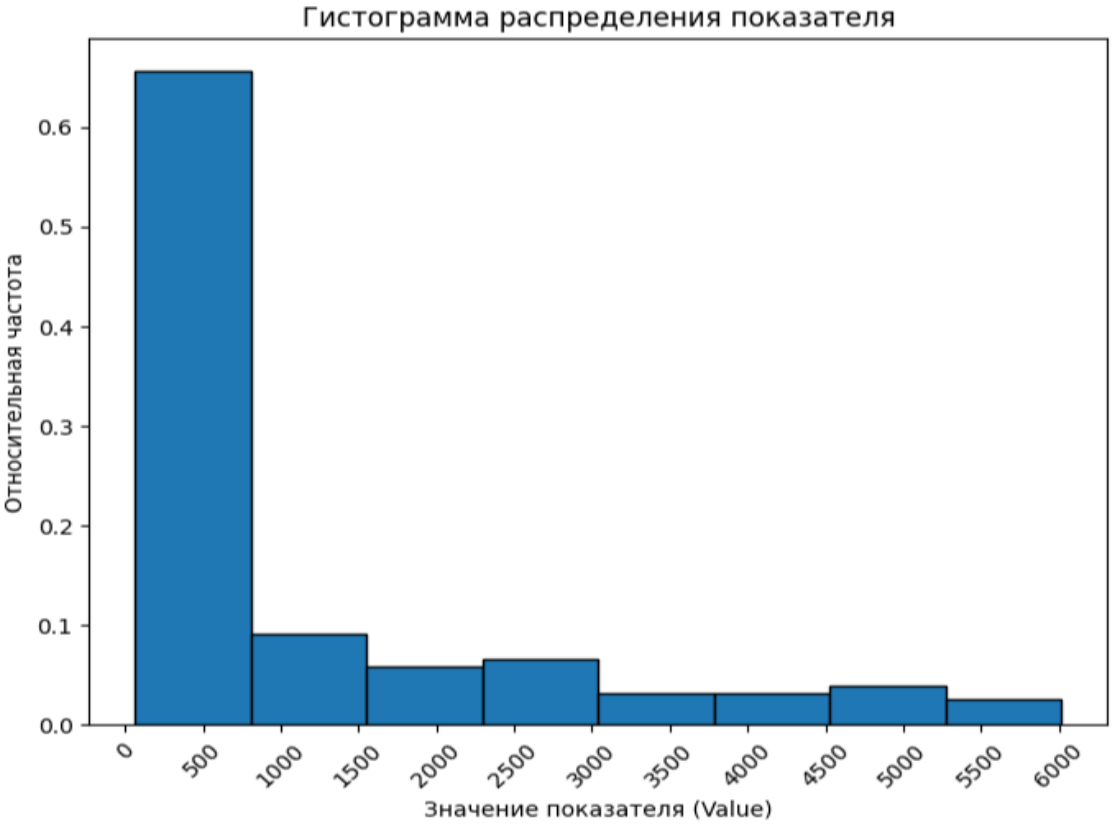

Рисунок 1 — Гистограмма распределения зарплат мужчин

Гистограмма распределения показателей зарплат женщин представлена на Рисунке 2.

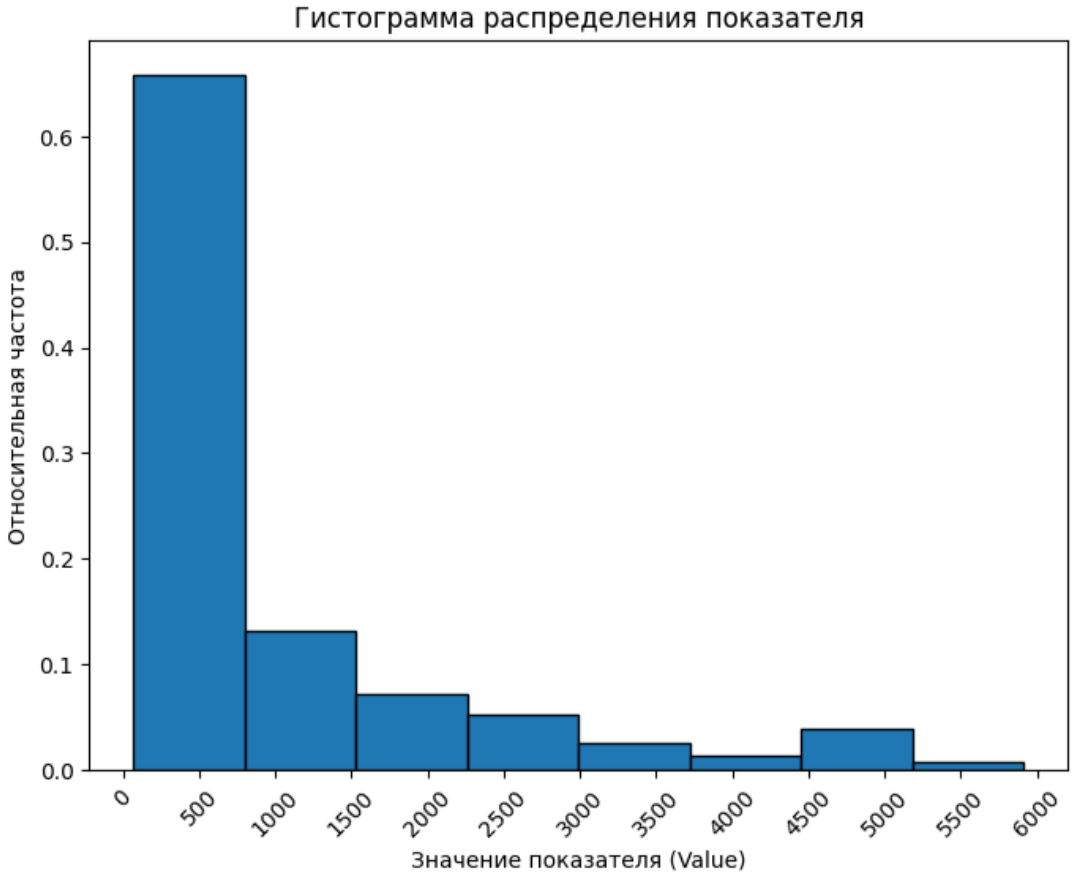

Рисунок 2 — Гистограмма распределения зарплат женщин

Гистограмма, изображающая распределение заработной платы и среди мужчин, и среди женщин в различных странах, демонстрируют выраженную правостороннюю асимметрию. Наиболее высокая относительная частота наблюдается в диапазоне низких значений дохода (до 1000 долларов), где сосредоточена основная часть выборки. Это указывает на то, что значительное число стран характеризуется сравнительно низким уровнем средней мужской заработной платы.

С увеличением значения показателя частота резко снижается, что отражает наличие небольшого количества стран с высокими доходами. Такая форма распределения типична для глобальных экономических данных, где преобладают развивающиеся страны с ограниченным уровнем оплаты труда, и лишь малая доля наблюдений относится к экономически развитым регионам.

Сравнивая обе таблицы, можно сказать, что правосторонняя асимметрия выглядит одинаково и у мужчин, и у женщин.

Эмпирическая функция распределения представляет собой инструмент статистического анализа, который позволяет описать, как распределены значения выборки, не предполагая заранее форму теоретического распределения. Она показывает, какая доля наблюдений имеет значения, меньшие либо равные определённому порогу, и строится напрямую на основе фактических данных, что делает её универсальным способом визуализации и изучения структуры выборки как для дискретных, так и для непрерывных признаков.

Эмпирическая функция распределения зарплат мужчин представлена на Рисунке 3.

Рисунок 3 — Эмпирическая функция распределения зарплат мужчин

Эмпирическая функция распределения зарплат мужчин представлена на Рисунке 4.

Рисунок 4 — Эмпирическая функция распределения зарплат женщин

Эмпирические функции распределения для мужчин и женщин отражают общие тенденции.

Для мужчин ЭФР демонстрирует выраженно ступенчатый рост, что указывает на неравномерное распределение доходов. Значительная часть наблюдений сосредоточена в нижних диапазонах значений заработной платы, после чего функция растёт медленнее, постепенно приближаясь к 1. Это говорит о том, что большинство мужчин в выборке получают относительно невысокие доходы, а доля стран с высокими зарплатами заметно меньше.

Для женщин ЭФР имеет схожую форму, однако её рост в нижней части диапазона более концентрированный. Это означает, что среди женщин ещё большая доля наблюдений приходится на низкие значения дохода, а увеличение заработков происходит реже и менее равномерно.

В целом, сравнение эмпирических функций показывает, что в обеих группах наблюдается неравномерное распределение доходов и сильная правосторонняя асимметрия.

Рассчитаем основные параметры данных.

Выборочное среднее отражает среднее значение признака в выборке. Выборочное среднее рассчитывается по следующей формуле:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i, \tag{1.4}$$

где n — размер выборки;

x_i — i-е наблюдение.

Выборочная дисперсия характеризует разброс данных вокруг среднего значения. Она показывает, насколько сильно доля городского населения различается между странами и рассчитывается по следующей формуле:

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n} (x_i - \bar{x})^2, \tag{1.5}$$

где $\bar{x}$ — выборочное среднее;

x_i — i-е наблюдение;

n — размер выборки.

Выборочное стандартное отклонение — это квадратный корень из дисперсии, отражает среднее отклонение данных от среднего. Оно позволяет оценить разброс в тех же единицах, что и сам признак. Выборочное стандартное отклонение рассчитывается по следующей формуле:

$$s = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n} (x_i - \bar{x})^2}, \tag{1.6}$$

где $\bar{x}$ — выборочное среднее;

x_i — i-е наблюдение;

n — размер выборки.

Коэффициент вариации показывает относительный разброс данных относительно среднего и выражается в процентах. Он особенно полезен для сравнения вариабельности признака между разными выборками. Коэффициент вариации рассчитывается по формуле:

$$CV = \frac{s}{\bar{x}} \bullet 100\%, \tag{1.7}$$

где s — выборочное стандартное отклонение;

$\bar{x}$ — выборочное среднее.

Программный расчет параметров представлен на Листинге 4.

Листинг 4 — Расчёт основных параметров данных

```
def analyze_file(df):
    n = len(df)
    g = round(1 + math.log2(n))
    val = df['Value'].astype('float')
    val = val.reset_index(drop=True)
    print("Стандартное отклонение:", val.std(ddof=1))
    print("Дисперсия:", val.var(ddof=1))
    print("Коэффициент  вариации:",  str(round(float(val.std()  /
val.mean() * 100), 2)) + '%')
print("Среднее:", val.mean())
```

В ходе анализа данных были получены ключевые статистические показатели для двух групп: мужчин и женщин. Для группы мужчин среднее значение равно 1206,41 доллар, а стандартное отклонение от среднего составляет 1475,24 долларов. В группе женщин среднее значение равно 995,28 долларов, а стандартное отклонение — 1217,62 доллара. Таким образом, среднее значение исследуемого показателя у мужчин выше, чем у женщин, примерно на 258,2 единиц, что составляет около 21% от среднего показателя женской группы.

Значения дисперсии и стандартного отклонения демонстрируют больший абсолютный разброс данных в мужской группе. Выборочная дисперсия у мужчин ($\approx 2{,}17 \times 10^6$) заметно выше, чем у женщин ($\approx 1{,}48 \times 10^6$), а стандартное отклонение у мужчин больше, чем у женщин. Это связано с тем, что при более

высоком среднем у мужчин абсолютный разброс величин так же становится больше.

Коэффициенты вариации для обеих групп оказались практически одинаковыми: 122,28% у мужчин и 122,34% у женщин. Такие высокие значения свидетельствуют о высоком показателе неравенства в мире. Стандартное отклонение сравнимо по величине со средним значением в каждой группе, что указывает на значительный разброс исследуемого показателя внутри каждой группы.

Таким образом, можно заключить, что хотя среднее значение исследуемого показателя выше в мужской группе, относительная изменчивость данных в группах мужчин и женщин находится примерно на одном и том же высоком уровне. Эти результаты подчеркивают существенные различия в среднем уровне показателя между полами при одновременном высоком уровне вариабельности внутри каждой группы.

1.2 Вычисление точечных оценок

Для анализа предполагаем, что рассматриваемая выборка x подчиняется логнормальному распределению, то есть $Y = \ln x$ нормально распределена.

Метод максимального правдоподобия (ММП) — один из наиболее распространённых способов построения точечных оценок параметров распределения случайной величины. Его идея заключается в выборе таких значений параметров, при которых вероятность получить наблюдаемую выборку данных является максимальной.

Параметрами распределения в логарифмической шкале являются μ (математическое ожидание) и σ^2 (дисперсия). Вычислим оценки параметра. Функция правдоподобия имеет вид:

$$Y(\mu, \sigma^2) = -\frac{n}{2}\ln 2\pi - \frac{n}{2}\ln\sigma^2 - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i - \mu)^2. \quad (1.9)$$

Свойства оценок методом максимального правдоподобия при логнормальном распределении имеет следующие свойства:

- Несмещенность. оценка μ является несмещённой, а смещение σ^2 становится несущественным с ростом элементов в выборке.
- Состоятельность. По мере увеличения объёма выборки оценки ММП сходятся к истинным значениям параметров. В нашем случае выборка достаточно велика, следовательно можно утверждать, что оценки являются состоятельными.
- Эффективность. Для нормального распределения оценки, полученные методом максимального правдоподобия, являются асимптотически эффективными — то есть обладают наименьшей возможной дисперсией среди всех несмещённых оценок.
- Асимптотическая нормальность. При большом распределение оценок близко к нормальному, что позволяет использовать доверительные интервалы и проверку гипотез на основе стандартного нормального распределения.

Метод моментов — подход к оценке параметров распределения, основанный на приравнивании теоретических моментов распределения к вычисленным выборочным моментам. Идея метода заключается в том, что параметры модели подбираются так, чтобы значения моментов совпадали в выборке и теории.

В рассматриваемой реализации логнормального распределения метод моментов на логарифмах даёт те же оценки μ и σ^2

Свойства оценок методов моментов:

- Несмещенность. Оценка дисперсии, рассчитанная по методу моментов, является несмещённой, поскольку при вычислении используется деление на n – 1. Оценка среднего также несмещённая.

- Состоятельность. При увеличении размера выборки оценки и сходятся к истинным значениям.
- Эффективность. Оценки по методу моментов немного менее эффективны, чем ММП (их дисперсия чуть выше). Однако при большом объёме различия невелики.
- Асимптотическая нормальность. Как и в случае ММП, при больших n распределение оценок приблизительно нормальное, что позволяет применять обычные методы статистического вывода.

Байесовский подход основывается на применении априорного (изначального) распределения для параметров и обновлении информации о них после наблюдения данных. Работа метода заключается в следующей формуле:

$$p(Y|\theta) = \frac{p(x|\theta)p(\theta)}{p(x)}, \tag{1.10}$$

где $p(\theta)$ — априорное распределение параметра;

$p(x|\theta)$ — функция правдоподобия;

$p(\theta|x)$ — апостериорное распределение.

Рассмотрим нормальное распределение и зададим слабо информативные априорные распределения (что часто используется в практическом анализе при отсутствии априорных знаний). В таком случае Байесовская оценка параметра равна:

$$\hat{\mu} = E(\mu|x) = \overline{\ln x} \tag{1.11}$$

Для дисперсии при неинформативном априоре используется аналогичный результат:

$$E(\sigma^2|x) = \frac{(n-1)s^2}{(n-3)}, \tag{1.12}$$

где s^2 — выборочная дисперсия.

Свойства Байесовский оценок:

- Несмещенность. При выбранном неинформативном априорном распределении оценка среднего совпадает с выборочным средним, что делает её несмещённой. Оценка дисперсии имеет малое априорное смещение, которое становится пренебрежимо малым при большом объёме выборки.
- Состоятельность. Байесовские оценки сходятся к истинным параметрам при увеличении числа наблюдений, поэтому являются состоятельными.
- Эффективность. В условиях большого объёма выборки Байесовская оценка среднего практически идентична ММП и обладает близкой к оптимальной дисперсии, то есть является асимптотически эффективной.
- Асимптотическая нормальность. При больших nапостериорное распределение для среднего приближается к нормальному закону, что позволяет использовать стандартные методы построения доверительных интервалов и проверки гипотез.

Код для вычисления вышеприведённых точечных оценок представлен на Листинге 5.

Листинг 5 — Расчёт методом Байеса

```
def analyze_lognormal(col):

    y = np.log(col)
    n = len(col)
    mu_log = np.mean(y)
    s2_log_unbiased = np.var(y, ddof=1)

    mu_mle = mu_log
    sigma2_mle = np.mean((y - mu_mle)**2)

mu_mm = mu_log
    sigma2_mm = sigma2_mle

sigma2_bayes = ((n - 1) * s2_log_unbiased) / (n - 3)
    bayes_note = None
```

Продолжение Листинга 5.

```
    mu_bayes = mu_log

    mean_mle = np.exp(mu_mle + sigma2_mle / 2)
    var_mle = (np.exp(sigma2_mle) - 1) * np.exp(2 * mu_mle + sigma2_mle)

    mean_bayes = np.exp(mu_bayes + sigma2_bayes / 2) if not
np.isnan(sigma2_bayes) else np.nan

    var_bayes = ((np.exp(sigma2_bayes) - 1) * np.exp(2 * mu_bayes +
sigma2_bayes)
                 if not np.isnan(sigma2_bayes) else np.nan)
```

В результате оценки логнормального распределения для мужской и женской выборок получена единая картина: все три метода – максимального правдоподобия, моментов и байесовский – дали практически согласованные значения точечных оценок. В частности, метод моментов дал те же значения, что и MLE, а байесовские оценки лишь незначительно выше.

Так, оценка математического ожидания в исходной шкале для мужчин составляет около 1190.5 (по MLE) и 1206.4 (по Байесу), тогда как для женщин она равна примерно 993.5 и 1006.7 соответственно.

Оценки дисперсий также выше у мужчин ($\sim 3.996 \cdot 10^6$ и $\sim 4.254 \cdot 10^6$) по сравнению с женщинами ($\sim 2.665 \cdot 10^6$ и $\sim 2.836 \cdot 10^6$). Это означает, что в мужской группе исследуемая величина в среднем больше и при этом распределена более разбросанно, чем в женской группе.

Высокие значения дисперсий говорят о большой вариативности выборок: значительная часть наблюдений может сильно отличаться от среднего, что типично для логнормального распределения. Подчеркивается стабильность оценок, что свидетельствует о надежности выводов.

В результате проведённого анализа выявлено, что распределение среднемесячных зарплат как мужчин, так и женщин по странам мира характеризуется сильной правосторонней асимметрией: основная часть наблюдений сосредоточена в низших диапазонах дохода, небольшая доля стран имеет существенно более высокие средние зарплаты. Среднее значение зарплаты у мужчин значительно выше, чем у женщин — разница составляет около 20,7% — при этом обе выборки демонстрируют очень большой разброс (выборочное

стандартное отклонение $\approx 1475{,}2$ у мужчин и $\approx 1217{,}6$ у женщин). Коэффициенты вариации ($\sim 122\%$ в каждой группе) указывают на высокий уровень неравномерности и вариативности данных. Оценки параметров при предположении логнормального распределения (методы максимального правдоподобия, моментов и байесовский подход) оказались согласованными: все методы дали близкие значения оценок средних и дисперсий, причём дисперсия мужской выборки заметно превосходит женскую. Таким образом, исследуемые данные характеризуются устойчивым гендерным разрывом в оплате труда. А именно мужчины в среднем зарабатывают больше, чем женщины и при этом высокой изменчивостью.

2 ОЦЕНКА ПАРАМЕТРОВ РАСПРЕДЕЛЕНИЯ

2.1 Расчёт точечных оценок и доверительных интервалов

Рассчитаем точечные оценки для обрабатываемых данных.

Медиана — центральное значение в упорядоченном наборе данных, которое делит выборку на две равные части. Расчёт медианы для упорядоченной выборке представлен на Формуле 2.1:

$$\begin{cases} M = \dfrac{x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}}{2}, \text{при } n - \text{чёт.} \\ M = x_{\left(\frac{n}{2}\right)}, \text{при } n - \text{нечёт.} \end{cases}, \tag{2.1}$$

где n — размер выборки;

x_i — i-е наблюдение.

Мода — наиболее часто встречающееся значение в выборке. Для непрерывных данных мода определяется как значение с максимальной плотностью (Формула 2.2):

$$mode(x) = \arg max\, f(x) \tag{2.2}$$

Математическое ожидание случайной величины это её средневзвешенное по вероятностям значение. В непрерывных данных можно использовать среднее арифметическое значение. Математическое ожидание для непрерывной случайной величины рассчитывается по следующей формуле:

$$E[x] = \int_{-\infty}^{\infty} x f(x)\, dx, \tag{2.3}$$

где $f(x)$ — плотность распределения.

Выборочная дисперсия характеризует разброс данных вокруг среднего значения. Она показывает, насколько сильно доля городского населения различается между странами и рассчитывается по следующей формуле:

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2, \tag{2.4}$$

где $\bar{x}$ — выборочное среднее;

x_i — i-е наблюдение;

n — размер выборки.

Выборочное стандартное отклонение — это квадратный корень из дисперсии, отражает среднее отклонение данных от среднего. Оно позволяет оценить разброс в тех же единицах, что и сам признак. Выборочное стандартное отклонение рассчитывается по следующей формуле:

$$S = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2}, \tag{2.5}$$

где $\bar{x}$ — выборочное среднее;

x_i — i-е наблюдение;

n — размер выборки.

Для интервальных оценок строим доверительные интервалы для математического ожидания и дисперсии с надежностью $\gamma = 0.95$. Под предположением нормальности распределения: доверительный интервал для логнормального ожидания (при известной дисперсии или большой выборке) рассчитывается по Формуле 2.6:

$$\bar{X} - t_{n-1,\frac{\alpha}{2}} \cdot \frac{S_x}{\sqrt{n}}, \bar{X} + t_{n-1,\frac{\alpha}{2}} \cdot \frac{S_x}{\sqrt{n}}, \tag{2.6}$$

где $\bar{X}$ — выборочное среднее;

S_x — выборочное стандартное отклонение.

Код для вычисления вышеприведённых точечных оценок представлен на Листинге 6.

Листинг 6 — Расчёт точечных оценок

```
def file_evaluation(df):
    n = len(df)

    val = df['Value'].astype('float')
    log_val = np.log(val)

    print("Медиана:",np.median(val))
    print("Среднее:", val.mean())
    print("Стандартное отклонение:", val.std(ddof=1))
    print("Дисперсия:", val.var(ddof=1))
    print("Математическое ожидание:", val.mean())

    xs = np.linspace(val.min(), val.max(), n*3)
    ys = gaussian_kde(val)
    print("Мода: ",xs[np.argmax(ys)])

    sd = val.std(ddof=1)
    mean = val.mean()
    t_q = t.ppf(1 - 0.95/2, df=n-1)
    se = sd / np.sqrt(n)
    ci_low = mean - t_q * se
    ci_high = mean + t_q * se
    print(f"Доверительный интервал: [{ci_low}, {ci_high}]")
```

Сравнивая средние, медианы и моды в обеих группах, можно увидеть обычную для правосторонних распределений картину: среднее значительно превышает значение медианы, а медиана кратно превышает моду. У женщин среднее равное 995.6 долларам больше, чем вдвое превышает медиану равную 424.2 долларам. Мода, равная 138.87 долларам примерно в 3 раза меньше медианы. У мужчин примерно такие же результаты: 1206.4 доллара больше, чем вдвое выше медианы равной 507.8 долларов. Мода равная 148.8 долларам так же заметно ниже медианы. Также необходимо отметить, что выборочное среднее, медиана и мода у мужчин слегка выше, чем у женщин.

Значения дисперсии и стандартного отклонения демонстрируют больший абсолютный разброс данных в мужской группе. Выборочная дисперсия у мужчин ($\approx 2{,}19 \times 10^6$) заметно выше, чем у женщин ($\approx 1{,}51 \times 10^6$), а стандартное отклонение у мужчин больше, чем у женщин. Это связано с тем, что при более

высоком среднем у мужчин абсолютный разброс величин так же становится больше.

Доверительные интервалы для среднего составляют от 989,12 до 1001,45 у женщин и от 1198,95 до 1213,88 у мужчин. Такой интервал должен покрывать истинный параметр среднего с вероятностью в 95%. Для женщин и для интервал попадает в выборочное среднее. Также интервалы и у мужчин, и у женщин крайне далеки от выборочной медианы в меньшую сторону из-за сильной скошенности плотности распределения вправо.

2.2 Расчёт оценок и критериев

Выберем критерии, которые подходят к теме и к исследуемым данным из выданного перечня: критерий Харке-Бера, критерий максимального правдоподобия, критерий Манна-Уитни.

Метод максимального правдоподобия используют для оценки параметров предполагаемой модели, что не подходит для задачи сравнения двух групп, также данный момент мы не можем чётко назвать распределение выборок, что ещё существеннее усложняет работу с этим методом.

Критерий Харке-Бера проверяет, насколько выборочное распределение отличается по асимметрии и эксцессу от нормального. Нулевая гипотеза утверждает, что данные имеют нормальное распределение. Чем ближе распределение к нормальному, тем меньше статистика Харке-Бера отличается от нуля.

Для выборки размера n вычисляют выборочные центральные моменты по формуле:

$$m_k = \frac{1}{n}\sum_{1=1}^{n}(x_i - x)^k\,, \tag{2.7}$$

где k — порядок момента.

Затем по следующим формулам вычисляют показатель выборочной асимметрии по следующей формуле:

$$g_1 = \frac{m_3}{m_2^{\frac{3}{2}}}, \tag{2.8}$$

Высчитаем выборочный эксцесс — показатель, который описывает остроту вершины распределения и тяжесть хвостов выборочных данных по сравнению с нормальным распределением по следующей формуле:

$$g_2 = \frac{m_4}{m_2^2} - 3, \tag{2.9}$$

И, наконец, критерий Харке-Бера вычисляется по следующей формуле:

$$JB = \frac{n}{6}\left(g_1^2 + \frac{g_2^2}{4}\right), \tag{2.10}$$

Программная реализация критерия Харке-Бера для распределений зарплат у мужчин и у женщин представлена на Листинге 7.

Листинг 7 — Расчёт критерия Харке-Бера

```
jb_men_stat, jb_men_p = stats.jarque_bera(men)
jb_women_stat, jb_women_p = stats.jarque_bera(women)


print(f"men: JB = {jb_men_stat:.3f}, p-value = {jb_men_p:.4f}")
print(f" women: JB = {jb_women_stat:.3f}, p-value = {jb_women_p:.4f}")
```

Проанализируем полученные результаты: значение статистики Харке-Бера и у мужчин, и у женщин далеки от нуля: 140.16 и 163.63 соответственно, p-значение у обеих групп близко к нулю. Это говорит нам о том, что изучаемые данные не имеют нормального распределения.

U-критерий Манна-Уитни — тест, помогающий сравнить две независимые группы и понять, есть ли между ними статистически значимые различия. Нулевая гипотеза утверждает, что нет никаких статистически значимых различий между распределениями двух выборок. Альтернативная гипотеза говорит о различии распределения двух выборок: значения из одной выборки систематически выше или ниже значений из другой.

Для применения критерия необходимо составить ранжированный ряд из обеих выборок, расставив их элементы по степени возрастания признака, приписывая соответствующий ранг. Затем следует разделить проранжированный ряд на элементы первой и второй выборок. Подсчитать отдельно сумму рангов элементов выборок. После этого вычислим U-критерий для обеих выборок по следующим формулам:

$$U_1 = n_1 \cdot n_2 + \frac{n_1 \cdot (n_1 + 1)}{2} - R_1, \tag{2.11}$$

где n_i — количество элементов в выборке i;

R_i — сумма рангов выборки i.

$$U_2 = n_1 \cdot n_2 + \frac{n_2 \cdot (n_2 + 1)}{2} - R_2, \tag{2.12}$$

где n_i — количество элементов в выборке i;

R_i — сумма рангов выборки i.

Затем определим значение U-статистики Манна-Уитни, сравним его с критическим значением критерия данных, делаем выводы по полученной статистике и p-значению. Программная реализация критерия Манна-Уитни для распределений зарплат у мужчин и у женщин представлена на Листинге 8.

Листинг 8 — Расчёт критерия Манна-Уитни

```
res = stats.mannwhitneyu(men, women, alternative='two-sided')
U_stat = res.statistic
print(f" U = {U_stat:.3f}")
print(f"p-value ( = {res.pvalue:.4f}")
```

Проанализируем полученные результаты: минимальная сумма рангов выборок равна 11926, полученное p-значение равно 0.12. Полученное p-значение получилось больше критического значения в 0.05, соответственно мы принимаем нулевую гипотезу. Данный критерий говорит нам о том, что нет достаточных статистических оснований утверждать о различии распределений. Такой результат может быть получен из-за недостаточной выборки или низком расхождении между выборками зарплат мужчин и женщин.

2.3 Оценка распределений и плотностей

Проведём оценку распределений и плотностей, что позволит приближённо определить функции распределения или функции плотности вероятности случайной величины в имеющейся выборке.

Исходя из результатов критерия Харке-Бера, можем утверждать, что данные не имеют нормального распределения. Зарплаты в более развитых странах и в группе мужчин, и в группе женщин тянут хвост распределения вправо. Точечные оценки медиан и выборочных средних в обеих группах подтверждают эту мысль. Гистограмму плотности распределения выборок визуально можно соотнести с логнормальным распределением. Код, реализующий гистограмму плотности обеих выборок, функцию оценки плотности распределения, кривую плотности подогнанного логнормального распределения и вертикальные линии для среднего и медианы обеих выборок изображен на Листинге 9.

Листинг 9 — Оценка распределений и плотностей

```
fig, axes = plt.subplots(1, 2, figsize=(12, 4))

ax = axes[0]

shapem, locm, scalem = stats.lognorm.fit(men, floc=0)
xm = np.linspace(np.min(men), np.max(men), 200)
lognormm = stats.lognorm.pdf(xm, shapem, loc=locm, scale=scalem)
sns.histplot(men, bins=8, stat='density', alpha=0.6, ax=ax)
sns.kdeplot(men, label='KDE', color='red', clip=(0, None), ax=ax)
```

Продолжение Листинга 9

```
ax.plot(xm, lognormm, color='purple', label='ЛогНорм')
ax.axvline(np.mean(men),   color='black',   linestyle='--',   label=f'Среднее
{np.mean(men):.2f}')

ax.axvline(np.median(men), color='black', linestyle='dotted', label=f'Медиана
{np.median(men):.2f}')
ax.set_title('men')

ax.legend()
ax.set_xlabel('Значение')
ax.set_ylabel('Плотность')
ax = axes[1]

shapew, locw, scalew = stats.lognorm.fit(women, floc=0)
xw = np.linspace(np.min(women), np.max(women), 200)
lognormw = stats.lognorm.pdf(xw, shapew, loc=locw, scale=scalew)

sns.histplot(women, bins=8, stat='density', alpha=0.6, ax=ax)
sns.kdeplot(women, label='KDE', color='red', clip=(0, None), ax=ax)
ax.plot(xw, lognormw, color='purple', label='ЛогНорм')

ax.axvline(np.mean(women),   color='black',   linestyle='--',   label=f'Среднее
{np.mean(women):.2f}')
ax.axvline(np.median(women), color='black', linestyle='dotted', label=f'Медиана
{np.median(women):.2f}')
ax.set_title('women')

ax.legend()
ax.set_xlabel('Значение')
ax.set_ylabel('Плотность')

plt.tight_layout()
plt.show()
```

Полученная визуализация представлена на Рисунке 5.

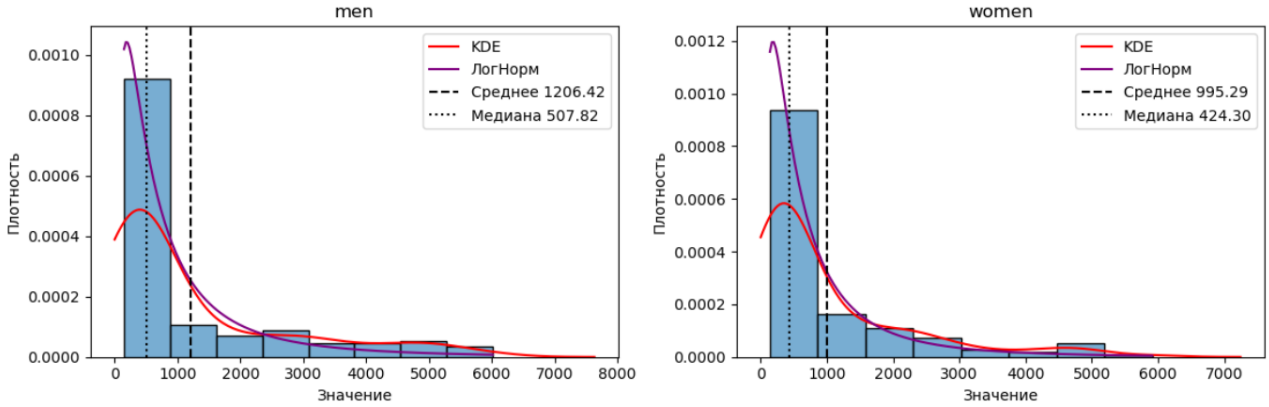

Рисунок 5 — Оценка распределений и плотностей

Исходя из полученных графиков можно сказать, что логнормальное распределение хорошо ложится на гистограмму плотности распределения, KDE корректно показывает высокую плотность при малых значениях зарплат и примерно повторяет предположенное логнормальное распределение.

2.4 Формирование гипотез

2.4.1 Гипотеза о равенстве средних

Нулевая гипотеза: средние значения двух выборок или среднее выборки и известное значение равны.

Альтернативная гипотеза: средние значения не равны.

Воспользуемся двусторонним t-тестом. Программная реализация t-статистики реализована на Листинге 10.

Листинг 10 — Расчёт двустороннего t-теста

```
t_stat, p_t = stats.ttest_ind(men, women, equal_var=True)
print(f"T-статистика={t_stat:.3f}, p-value={p_t:.3f}")
```

Разберём полученный расчёт. Значение t-статистики равно 1.185, полученное p-значение равно 0.236.

Такое положительное значение t-статистики говорит о том, что среднее в первой группе (мужчин) больше среднего во второй (женщин), но не сильно.

Полученное p-значение означает вероятность получить такую или более экстремальную t-статистику при условии, что нулёвая гипотеза верна. При обычном уровне значимости в 0.05 делаем вывод, что мы не отвергаем нулевую гипотезу. Следовательно, нет статистических оснований утверждать, что средние двух групп серьёзно различаются. Согласно геометрическому соотношению средних, геометрическая средняя у мужчин на 20 % больше, чем у женщин.

2.4.2 Гипотеза о лог-нормальности данных

Нулевая гипотеза: логарифмы наблюдений распределены нормально.

Альтернативная гипотеза: логарифмы наблюдений не распределены нормально.

Воспользуемся критерием Шапиро-Уилка к логарифмам данных. Его программная реализация изображена на Листинге 11.

Листинг 11 — Критерий Шапиро-Уилка

```
def shapiro_log(x, label='sample', alpha=0.05):
    x = np.asarray(x)
    x_log = np.log(x)
    stat, p = stats.shapiro(x_log)
    print(f"Shapiro {stat:.4f}, p-значение ={p:.3e}")
    return stat, p
shapiro_log(women)
shapiro_log(men)
```

Для женщин значение статистики = 0.9140, p-значение равно 0.000649, а для мужчин значение статистики = 0.9137, p-значение равно 0.000616. В обоих случаях p-значение ниже критерия значимости, поэтому нулевая гипотеза о нормальности логарифмов отвергается, следовательно лог-преобразованные значения у женщин и у мужчин статистически значимо не удовлетворяют нормальному распределению, следовательно нельзя утверждать, что данные логнормальны.

2.4.3 Гипотеза о равенстве дисперсий

Нулевая гипотеза: дисперсии в выборках мужчин и женщин равны.

Альтернативная гипотеза: дисперсии различаются.

Воспользуемся критерием Флиннера-Киллина о равенстве дисперсий. Его программная реализация изображена на Листинге 12.

Листинг 12 — Критерий Флиннера-Киллина

```
stat, p = stats.fligner(men, women)
print(f"statistic = {stat:.4f}, p = {p:.5e}")
```

Проанализируем полученные значения. Статистика теста равна 1.8389, что меньше порога критического значения, p-значение равно 0.1751, превышающий уровень значимости равный 0.05. Исходя из полученных результатов, мы не

отклоняем нулевую гипотезу. Следовательно, статистически значимых доказательств различия дисперсий между мужчинами и женщинами не обнаружено.

3 ИДЕНТИФИКАЦИЯ РАСПРЕДЕЛЕНИЯ

3.1 Критерий согласия Пирсона

Идентифицируем распределения исследуемых данных распределений зарплат мужчин и женщин с помощью критерия согласия Пирсона.

Критерий согласия Пирсона применяют для проверки гипотезы о соответствии эмпирического распределения предполагаемому распределению. Если полученная статистика превосходит критическое значение заданного уровня значимости со степенями свободы, то можно сказать, что теоретическое распределение не соответствует имеющемуся. Расчёт статистики для критерия согласия Пирсона представлен на Формуле 3.1:

$$\chi^2 = \sum_{i=1}^{n} \frac{(O_{\mathrm{i}} - E_{\mathrm{i}})^2}{E_{\mathrm{i}}}, \tag{3.1}$$

где O_{i} — наблюдаемая частота в интервале;

E_{i} — ожидаемая (теоретическая) частота в интервале;

n — число элементов выборки.

Код расчёта статистики критерия для логнормального распределения и распределения Рэлея представлен на Листинге 13.

Листинг 13 — Расчёт статистики критерия согласия Пирсона

```
val = df[col].values
    counts, edges = np.histogram(val, bins=8)
    low, up = edges[:-1], edges[1:]
    ret = pd.DataFrame({"low_interval": low, "up_interval": up, "abs_freq":
counts})
    n = len(val)

    mu_log = np.log(val).mean()
    sigma_log = np.log(val).std(ddof=1)
    Ni_norm = (lognorm.cdf(up, s=sigma_log, scale=np.exp(mu_log)) -
lognorm.cdf(low, s=sigma_log, scale=np.exp(mu_log))) * n
    ret["Ni_norm"] = Ni_norm
```

Продолжение Листинга 13

```
    obs_n, exp_n = _merge(ret["abs_freq"].values, Ni_norm)
    chi2_norm = np.sum((obs_n - exp_n) ** 2 / exp_n)
    v = len(obs_n) - 3
    za = chi2.ppf(0.95, v)
    print(f"χ² (логнормальное): {chi2_norm:.3f}, критическое {za:.3f}")

    sigma_ray = (np.sum(val ** 2) / (2.0 * n)) ** 0.5
    Ni_ray   =   (rayleigh.cdf(up,   scale=sigma_ray)   -   rayleigh.cdf(low,
scale=sigma_ray)) * n
    ret["Ni_rayleigh"] = Ni_ray

    obs_r, exp_r = _merge(ret["abs_freq"].values, Ni_ray)
    chi2_ray = np.sum((obs_r - exp_r) ** 2 / exp_r)
    df_ray = len(obs_r) - 2
    za_ray = chi2.ppf(0.95, df_ray)
    print(f"χ² (Рэлея: {chi2_ray:.3f}, критическое {za_ray:.3f}")
```

Проанализируем полученные результаты. Для мужчин: критерий согласия Пирсона показал $\chi^2 = 32.925$ для логнормального приближения при критическом значении 3.841 и $\chi^2 = 264.590$ для распределения Рэлея при критическом значении 7.815. В обоих случаях полученные значения статистики значительно превышают критические при уровне значимости $\alpha = 0.05$, следовательно, нулевую гипотезу о соответствии выборки зарплат мужчин этим теоретическим распределениям по этому критерию следует отвергнуть. Хотя статистика логнормального распределения близка к критическому значению.

Для женщин: критерий дал $\chi^2 = 12.579$ для логнормального приближения при критическом значении 3.841 и $\chi^2 = 155.484$ для распределения Рэлея при критическом значении 5.991. Аналогично мужчинами, оба полученных значения существенно превышают соответствующие критические уровни при $\alpha = 0.05$, поэтому нулевая гипотеза о соответствии распределению логнормального и рэлеевского также отвергается. Это указывает на то, что ни логнормальное, ни рэлеевское распределение не описывают распределение женских зарплат согласно данному критерию. Так же, как у мужчин, статистика критерия согласия Пирсона для логнормального распределения показывает результаты, очень приближённые к критическому значению.

В практическом плане такие результаты означают, что делать выводы, предполагая логнормальную или рэлеевскую модель для зарплат обеих групп,

небезопасно. Воспользуемся ещё одним методом проверки распределений на соответствие.

3.2 Метод анаморфоз

Идентифицируем распределения исследуемых данных распределений зарплат мужчин и женщин с помощью метода анаморфоз. Метод анаморфоз — это графический метод идентификации распределения, который преобразует координаты так, чтобы исходное распределение переменных перевелось к линейному виду при условии, что заданная формула соответствует распределению выборки. Использование анаморфоз приводит к выделению участков, соответствующих выбранному распределению. Путем перебора анаморфоз, соответствующих различным вероятностным распределениям, можно выбрать то распределение, которое линеаризует исходные данные наиболее хорошо. Построение анаморфоз основано, в частности, на следующих преобразованиях координат: логарифмирование, сдвиг и растяжение аргумента, инверсия функции или аргумента, сдвиговых фазовых траекториях.

Коэффициент детерминации R^2 используется для того, чтобы понять долю приведённых к линейному виду значений. Чем ближе коэффициент к 1, тем лучше.

Код расчёта статистики критерия для логнормального распределения и распределения Рэлея представлен на Листинге 14.

Листинг 14 — Метод анаморфоз

```
x = np.asarray(x)
    results = {}
    pos = x

    (osm_log,      osr_log),      (slope_log,      intercept_log,      r)      =
st.probplot(np.log(pos), dist='norm', fit=True)
    R2_log = float(r ** 2)

    results['lognorm'] = { 'R2': R2_log, 'slope': float(slope_log), 'intercept':
float(intercept_log)}
```

Продолжение Листинга 14

```
    (osm_ray,  osr_ray),  (slope_ray,  intercept_ray,  r)  =  st.probplot(x, dist='rayleigh', fit=True)
    R2_ray = float(r ** 2)
    results['rayleigh'] = {
        'R2': R2_ray,
        'slope': float(slope_ray),
        'intercept': float(intercept_ray)
    }

    if show_plots:
        fig, axes = plt.subplots(1, 2, figsize=(12, 5))

        ax = axes[0]
        ax.scatter(osm_log, osr_log, s=20)
        ax.plot(osm_log, slope_log * osm_log + intercept_log, linewidth=1)
        ax.set_title(f'ЛогНорм, R2={R2_log:.4f}')
        ax.set_xlabel('Теоретические квантили')
        ax.set_ylabel('ln(x)')

        ax = axes[1]
        ax.scatter(osm_ray, osr_ray, s=20)
        ax.plot(osm_ray, slope_ray * osm_ray + intercept_ray, linewidth=1)
        ax.set_title(f'Рэлея, R2={R2_ray:.4f}')
        ax.set_xlabel('Теоретические квантили')
        ax.set_ylabel('x')

        plt.tight_layout()
        plt.show()

    return results
```

Анаморфозы распределения Рэлея и логнормального распределения для значений зарплат мужчин изображены на Рисунке 6.

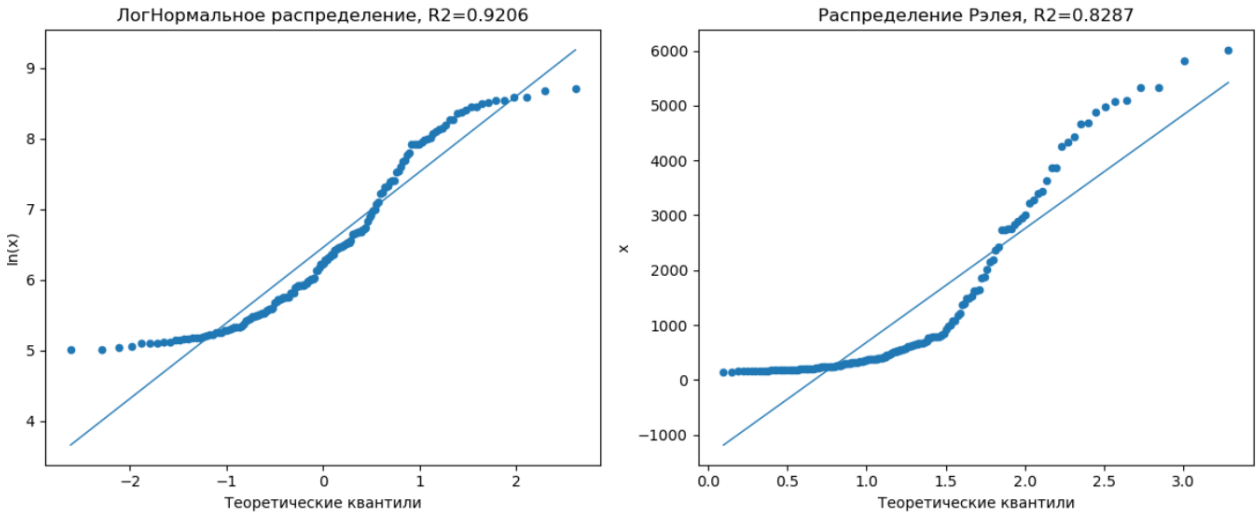

Рисунок 6 — Анаморфозы распределения зарплат мужчин

Анаморфозы распределения Рэлея и логнормального распределения для значений зарплат женщин изображены на Рисунке 7.

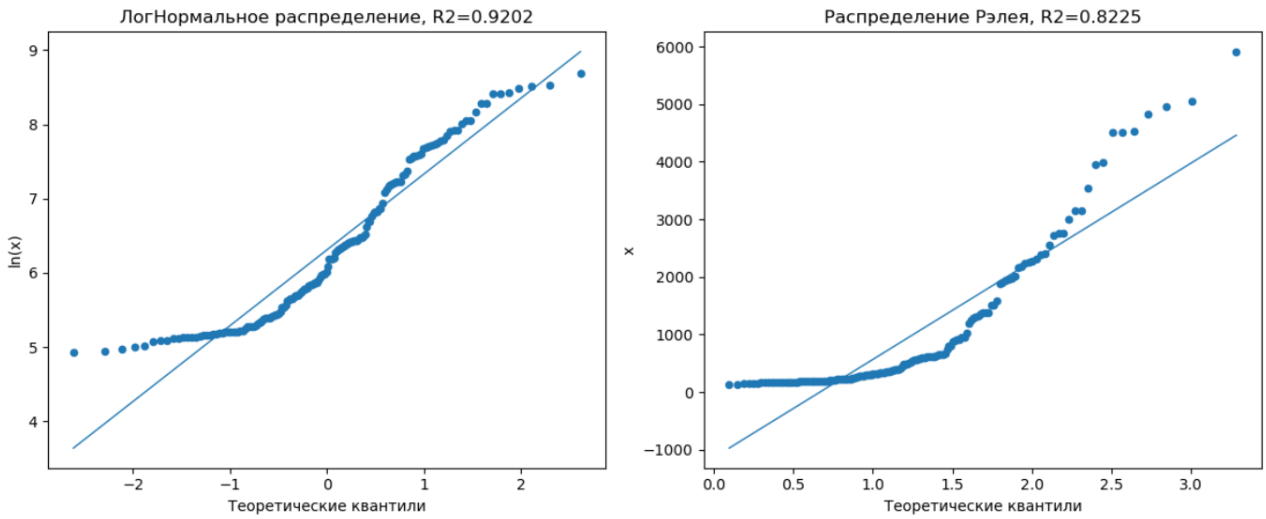

Рисунок 7 — Анаморфозы распределения зарплат женщин

Проанализируем полученные результаты: для мужчин коэффициент детерминации логнормального распределения равен 0.9206, что приближено к единице. Коэффициент детерминации для распределения Рэлея равен 0.8287, что относительно далеко от единицы, следовательно распределение не соответствует имеющимся данным. Полученные результаты говорят о приближённости распределения к логнормальному. В хвостах наблюдается наличие отклонений, значит модель логнормального распределения объясняет большую часть поведения данных, но недооценивает экстремальные большие значения.

По параметрам прямой найдём параметры распределения: в логнормальном распределении угловой коэффициент, соответствующий оценке стандартного отклонения логарифма от x, равен 1.07, свободный член, соответствующий оценке среднего значения логарифма x, равен 6.45. В распределении Рэлея угловой коэффициент, соответствующий мере разброса переменных, равен 2069.178, свободный член, соответствующий сдвигу графика по оси x, равен -1382,8.

Для женщин результаты схожи: коэффициент детерминации логнормального распределения равен 0.9201, что также приближено к единице. Коэффициент детерминации для распределения Рэлея равен 0.8224, что также относительно далеко от единицы, следовательно распределение не соответствует имеющимся данным. Полученные результаты говорят о приближённости распределения к логнормальному. В хвостах так же как и у мужчин наблюдается

наличие отклонений, значит модель логнормального распределения объясняет большую часть поведения данных, но недооценивает экстремальные большие значения.

По параметрам прямой найдём параметры распределения: в логнормальном распределении угловой коэффициент, соответствующий оценке стандартного отклонения логарифма от x, равен 1.02, свободный член равен 6.31. В распределении Рэлея угловой коэффициент, соответствующий мере разброса переменных, равен 1701.387, свободный член, соответствующий сдвигу графика по оси x, равен -1133,7.

3.3 Вывод на основе полученных результатов

На основе результатов, полученных из критерия Пирсона и метода анаморфоз, можно сказать, что распределения зарплат как у мужчин, так и у женщин демонстрируют приближённость к логнормальному распределению. Однако ни логнормальная, ни модель распределения Рэлея не обеспечивают полного соответствия данным: значения статистики критерия Пирсона существенно превышают критические, а метод анаморфоз выявляет отклонения, особенно в хвостах распределений. При этом коэффициенты детерминации для логнормального распределения значительно выше, чем для распределения Рэлея, что подтверждает лучшую аппроксимацию имеющихся данных. Распределения зарплат мужчин и женщин можно охарактеризовать как схожие и приближенно логнормальные по форме. Логнормальная модель описывает большинство наблюдений обеих групп, однако обе методики выявляют существенные отклонения в области крайних значений. Это показывает неполное соответствие данных ни у одной из рассматриваемых моделей.

ЗАКЛЮЧЕНИЕ

В работе был проведён статистический анализ гендерного неравенства зарплат в разных странах методами математической статистики. Были собраны и обработаны данные о среднемесячных зарплатах мужчин и женщин по различным странам, рассчитаны основные статистические характеристики, построены вариационные ряды, гистограммы и эмпирические функции распределения. Анализ показал, что распределение зарплат для обеих групп имеет выраженную правостороннюю асимметрию: наибольшие относительные частоты приходится на диапазоны низких доходов, а высокооплачиваемые страны составляют лишь малую долю выборки. Средняя зарплата мужчин превосходит среднюю зарплату женщин примерно на 20 %, при этом коэффициенты вариации для обеих групп весьма высоки, что свидетельствует о значительном неравенстве доходов у мужчин и у женщин и широком разбросе зарплат в разных странах.

Также были получены точечные оценки и построены доверительные интервалы параметров предполагаемого логнормального распределения зарплат. Рассчитанные средние и дисперсии выборки зарплат мужчин превосходят женские, что отражает более высокий уровень и большую вариабельность мужских доходов. Статистические критерии нормальности подтвердили, что обе выборки существенно отклоняются от нормального распределения, а критерий согласия Пирсона и анализ анаморфоз показали, что логнормальное распределение адекватно описывает данные, хотя в области высоких значений наблюдаются заметные отклонения. Ни двухвыборочный критерий Стьюдента, ни критерий Манна-Уитни не выявили статистически значимых различий между мужской и женской выборками. Тем не менее проведённые методы анализа согласованно указывают на устойчивый гендерный разрыв в оплате труда: мужчины в среднем зарабатывают значительно больше женщин причём как в странах с низким, так и с высоким уровнем дохода.

СПИСОК ИСТОЧНИКОВ

1. International Labour Organization. Indicators and data tools [Электронный ресурс]. — Geneva: ILO, 15 апр. 2024. — Режим доступа: http://ilostat.ilo.org/data/ (дата обращения: 20.09.2025).
2. International Labour Organization. The gender pay gap [Электронный ресурс]. — Geneva: ILO, 15 апр. 2024. — Режим доступа: https://www.ilo.org/resource/other/gender-pay-gap (дата обращения: 20.09.2025).
3. Кремер Н.Ш. Теория вероятностей и математическая статистика: учебное пособие. — 5-е изд. – М.: Юрайт, 2025. – 259 с.
4. Кузьмин В.И., Гадзанов А.Ф. Прикладные задачи математической статистики: учебное пособие. — М.: РТУ МИРЭА, 2011. — 92 с.
5. Вадзинский Р.Н. Справочник по вероятностным распределениям. — Спб.: Наука, 2001. — 296 с.
6. Чернова Н.И. Математическая статистика: учебное пособие. — Новосибирск: СибГУТИ, 2009. — 90 с.
7. Кобзарь А. И. Прикладная математическая статистика. Для инженеров и научных работников. — М.: ФИЗМАТЛИТ, 2006. – 816 с.
8. Тюрин Ю.Н., Макаров А.А. Статистический анализ данных на компьютере: учебное пособие — М.: ИНФРА-М, 2002. — 528 с.
9. SciPy. [Электронный ресурс] mannwhitneyu — SciPy v1.16.2 Manual — Сайт. — Режим доступа: https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.mannwhitneyu (дата обращения: 10.11.2025).
10. Хабр. «Анализ данных на Python» в двух частях [Электронный ресурс] — Блог компании «Образовательные проекты JetBrains». — katherins, 05.03.2019. — Режим доступа: https://habr.com/ru/companies/JetBrains-education/articles/438058/ (дата обращения: 10.11.2025).
11. Максимов Ю.Д., Куклин Б.А., Хватов Ю.А. Теория вероятностей. Контрольные задания с образцами решений. — СПб.: Изд-во СПбГПУ, 2002. — 96 с.

12. Ожерелкова Л.М., Тишаева И.Р., Антонова И.В. Основы математической статистики: учебное пособие — М.: РТУ МИРЭА, 2024. — 65 с.

13. Мицель А. А. Прикладная математическая статистика: учебное пособие. — Томск: Томский государственный университет систем управления и радиоэлектроники. — 2022. — 118 с.

14. Демин С.Е., Демина Е.Л. Математическая статистика: учебное пособие. — Нижний Тагил: НТИ (филиал) УрФУ, 2016. — 284 с.

15. Буданцев А.В. Прикладные задачи математической статистики: учебное пособие — М: РТУ МИРЭА, 2023. — 91 с.

16. Волкова Н.А., Кропачева Н.Ю., Михайлова Е.Г. Элементы математики и статистики: учебное пособие — СПб: Лань, 2018. — 128 с.